

基于聚类优化和决策树的 NIPT 研究策略

摘要

随着产前胎儿检测技术的不断发展，减少孕妇因胎儿异常导致治疗窗口期缩短的风险备受关注。本文基于附件中男胎和女胎的检测信息建立数学模型，实现孕妇 BMI 合理分组下各组 NIPT 最佳时点的选择和胎儿异常的判定，为产前检测技术发展做贡献。

针对问题一，为了分析胎儿 Y 染色体浓度与 BMI 等指标的相关性，本文首先进行男胎数据预处理，包括缺失值处理等，然后对各个数据的分布情况进行了研究，根据不同分布情况选择合适的 Spearman 相关系数或 Pearson 相关系数建立关系模型，最后运用相关系数的 P 值对显著性进行检验。结果显示，Y 染色体浓度与年龄等十二项指标呈显著负相关，与检测孕周等六项指标呈显著正相关，与 GC 含量等五项指标无相关关系。

针对问题二，首先为了解决 BMI 分组这个无监督聚类任务，本文使用了 K-Means++ 算法给出不同分组的 BMI 区间，并通过轮廓系数等三种指标确保分组结果最优。然后为了给出各组的最佳 NIPT 时点，本文通过 Logistic 回归构建胎儿不健康概率模型，再引入孕周惩罚函数与染色体浓度调整函数构建约束优化模型，使用 SLSQP 方法求解。最后本文从原始数据误差和检测结果有误考虑两类检测误差，分别使用 Gauss 噪声和包含、去除有误数据集的方法检验。结果显示，BMI 合理分组为 [26,31)、[31,35)、[35,41)，各组的最佳 NIPT 时点为 16w+5、17w+1、18w+1，原始数据误差对分组没有影响、对三组的时点影响较小，而检测结果有误对分组没有影响、对时点影响较小。

针对问题三，首先由于 Y 染色体浓度达标时间受多因素影响，为了实现 BMI 合理分组，本文先运用灰色关联分析筛选影响达标时间重要因素，由这些重要因素和 BMI 使用 K-Means++ 算法进行聚类。然后，由于不同组的 Y 染色体达标比例不同，达标率高的组可以沿用问题二方法确定时点，而达标率低的组需要验证检测结果可信度再沿用问题二方法，本文使用随机森林模型，以组内达标数据为训练集预测未达标数据再筛选结果不一致数据，最后本文仍考虑两类检测误差对于结果的影响。结果显示，BMI 合理分组为 [26,33)、[33,41)，两组的最佳 NIPT 时点为 16w+6、19w+6，原始数据误差和检测结果有误对分组没有影响、对两组的时点影响较小。

针对问题四，本文先进行了女胎数据预处理，包括缺失值处理等，其中为了确保检测结果准确性，运用 Logistic 模型给出了 X 染色体的达标阈值，然后由于影响女胎异常因素繁杂，本文使用随机森林的“Mean Decrease Accuracy”和“Mean Decrease Gini”指标筛选重要因素，然后用决策树模型生成关键因素的临界阈值与判定规则，并进行了十折交叉检验。结果显示，年龄、13 号染色体的 GC 含量、X 染色体浓度等共六个因素为重要影响因素，给出两个判定方法为：当年龄大于 32.5，被过滤掉读段数的比例小于 0.021，且 13 号染色体的 GC 含量大于 0.373 时，女胎出现异常的概率为 0.161 等规则。

关键词： Spearman 相关系数，K-Means++，Logistic 回归模型，随机森林，决策树

一、 问题重述

1.1 问题背景

无创产前检测（Non-invasive Prenatal Test，即 NIPT）作为一项重要的产前检测技术，相较于传统有创检查，其无需对孕妇造成创伤，仅需抽取母体血液，通过检测血液中的游离胎儿 DNA，即可评估胎儿是否存在染色体异常风险，因此深受广大准妈妈的青睐。而在实际检测中，如何针对不同 BMI 水平的孕妇精准确定最适 NIPT 检测时点，从而尽早发现不健康胎儿，对降低孕妇潜在风险至关重要 [1]。

1.2 问题提出

文件附件提供了多名孕妇的无创产前检测（NIPT）相关数据，数据维度涵盖孕妇基础身体指标，包括年龄、身高、体重及 BMI；也包含 NIPT 检测核心数据，例如测序质量关键参数（整体 GC 含量、13 号 / 18 号 / 21 号染色体的 GC 含量）、染色体浓度数据等；同时还记录了胎儿实际健康信息，为后续模型验证与结果分析提供了数据基础。现需结合前文所述的 NIPT 技术背景知识，依托附件中的具体数据，构建科学合理的数学模型，为下述问题提供系统性的分析与解决方案 [2]。

问题一：针对胎儿 Y 染色体浓度这一核心检测指标，根据附件数据，分析其与孕妇孕周数、身体质量指数（BMI）及其他相关指标（如年龄、身高、体重等）之间的内在关联特征与规律。给出描述胎儿 Y 染色体浓度与上述影响因素之间关系的关系模型，并对该模型的显著性进行检验。

问题二：由临床研究已知，对于怀有男胎的孕妇，BMI 是影响胎儿 Y 染色体浓度达到或超过 4%（即满足 NIPT 结果基本准确的浓度阈值）最早时间的核心因素。需基于此结论，对男胎孕妇的 BMI 进行科学、合理的分组，为每组孕妇确定进行 NIPT 检测的最佳时点，以最大限度降低因胎儿不健康却发现较晚导致治疗窗口期缩短的潜在风险。此外，还需分析可能存在的误差对 BMI 分组结果、最佳检测时点及潜在风险评估的影响。

问题三：胎儿 Y 染色体浓度的达标时间不仅受孕妇 BMI 影响，还与孕妇身高、体重、年龄等多种因素相关，同时需考虑检测误差及胎儿 Y 染色体浓度的达标比例，综合上述因素，以孕妇 BMI 为基础对男胎孕妇进行合理分组，确定每组对应的 BMI 区间及最佳 NIPT 检测时点，从而实现孕妇潜在风险最小化。同时，需进一步分析检测误差对分组合理性、最佳时点有效性及风险控制效果的影响。

问题四：由于孕妇与女胎均不携带 Y 染色体，NIPT 检测中女胎异常的判定需聚焦于染色体非整倍体情况。根据附件中女胎数据，综合纳入 X 染色体及 13 号、18 号、21 号染色体的 Z 值、各染色体的 GC 含量等相关指标及孕妇 BMI 等因素，以 13 号、18 号、21 号染色体非整倍体检测结果为判定结果，构建并给出一套可操作、科学的女胎异常判定方法。

二、 问题分析

2.1 问题 1 的分析

问题一是一个变量相关性分析问题，要求量化胎儿 Y 染色体浓度与孕妇孕周数、BMI 及其他指标的关联特性，构建两者间的关系模型，并通过显著性检验验证模型的可信度。首先，原始数据存在诸多干扰因素，如末次月经信息缺失等问题，因此必须先开展系统的数据预处理，进行缺失值处理、异常值处理等。其次，相关性分析需选择适配的数据分布特性的方法，Pearson 相关系数仅适用于正态数据，Spearman 相关系数可处理非正态或等级数据，因此需根据数据特点选择合适的相关系数；同时，为了结果的稳健性，需对计算出的相关系数进行显著性检验。基于以上认知，本文打算先完成数据预处理，再通过数据分布检验选择 Spearman 或 Pearson 相关系数计算关联程度，最后用 P 值检验显著性，结合可视化呈现关联特性，构建并验证关系模型。

2.2 问题 2 的分析

问题二是一个无监督聚类分组与约束优化问题，要求以 BMI 为核心依据对男胎孕妇进行合理分组，确定每组的 BMI 区间与最佳 NIPT 时点（需满足 Y 染色体浓度 4% 且孕妇潜在风险最小），同时分析检测误差对分组与时点结果的影响，最终为不同 BMI 孕妇提供精准的检测时点建议。首先，BMI 分组属于无监督学习任务，K-Means++ 算法通过选择距离尽可能远的初始簇中心，能提升聚类准确性，因此优先选用 K-Means++；但需确定最优簇数，所以本文引入轮廓系数等三种评价指标计算综合得分，确保分组结果最优。其次，最佳时点的核心是“潜在风险最小”，可认为风险来源于三方面：胎儿不健康概率、孕周早晚、Y 染色体浓度是否达标，因此本文先通过 Logistic 回归构建胎儿不健康概率模型，再引入孕周惩罚函数与染色体浓度调整函数，将风险量化，转化为约束优化问题。考虑到实际检测中存在两类检测误差，原始数据误差和检测结果有误，本文通过添加不同方差高斯噪声模拟原始数据误差，纳入或排除错误样本模拟误差验证稳健性。基于以上思考，本文打算先以问题一预处理后的数据为基础，用 K-Means++ 结合综合评价指标确定 BMI 最优分组，再通过 Logistic 回归、惩罚函数、调整函数构建约束优化模型，用 SLSQP 求解最佳时点，最后通过两类误差分析验证结果可靠性。

2.3 问题 3 的分析

问题三是一个多因素筛选、聚类分组、分场景优化的综合问题，要求在问题二基础上，综合身高、体重、年龄等多因素对 Y 染色体浓度达标时间的影响，结合检测误差与 Y 染色体浓度达标比例，基于 BMI 完成合理分组并确定每组最佳 NIPT 时点，最终进一步降低孕妇潜在风险。首先，题目明确染色体浓度达标时间受多因素影响，需先筛选关键影响因素：灰色关联适合因剔除不达标浓度数据导致样本量减少的场景，因此用该方法筛选指标。其次，分组需结合 BMI 与筛选出的关键因素，本文仍采用 K-Means++

算法。同时，不同组的 Y 染色体浓度达标比例不同也会影响到时点选择的可信度，因此需先统计各组达标比例，分场景制定时点策略：达标率高的组可沿用问题二的“Logistic 回归 + 惩罚函数 + SLSQP”方法，达标率低的组需先验证数据可信度。而随机森林能降低过拟合、鲁棒性强，适合训练达标数据模型以筛选测试集中可信数据，再应用问题二的优化方法。检测误差类型与问题二一致，仍需通过添加高斯噪声、纳入或排除错误样本分析影响。基于以上认知，本文打算先通过灰色关联分析筛选 Y 染色体达标时间的关键影响因素，再结合 BMI 与关键因素用 K-Means++ 确定最优分组，统计达标比例后分场景优化时点，最后通过两类误差验证结果稳健性。

2.4 问题 4 的分析

问题四是一个多因素综合分类判定与阈值优化问题，要求以女胎孕妇的 21 号、18 号、13 号染色体非整倍体为判定结果基准，综合 X 染色体及上述染色体的 Z 值、GC 含量等多维度因素，构建女胎异常判定方法，实现对女胎异常的识别。首先，原始女胎数据存在多重干扰：部分孕周超出临床检测范围等，因此必须先开展数据预处理，如缺失值处理等。其次，影响女胎异常的因素繁杂，若直接纳入所有因素，会导致模型冗余，需先筛选对女胎异常影响显著的核心因素。再者，判定方法需具备可操作性，即需量化关键因素的临界阈值且需验证方法的稳健性，避免因模型过拟合或噪声数据生成“虚假判定规则”。考虑到 X 染色体浓度是 NIPT 结果准确的核心前提，需先通过统计模型确定其阈值以筛选可信数据。而决策树模型能通过“分割数据”生成直观的临界值规则，但易受噪声影响，因此需搭配交叉验证确保结果可靠；随机森林的“Mean Decrease Accuracy”和“Mean Decrease Gini”指标可有效衡量特征重要性，适合从多因素中筛选核心成分。基于以上认知，本文打算先开展数据预处理，剔除超范围孕周数据、以 Logistic 回归确定 X 染色体浓度阈值筛选可信数据等；再采用随机森林模型，通过“Mean Decrease Accuracy”和“Mean Decrease Gini”得分筛选出对女胎异常影响最大的核心因素；随后用决策树模型生成关键因素的临界阈值与判定规则，最后通过十折交叉验证验证模型准确性，确定高可信度的女胎异常判定方法。

三、 模型假设

1. GC 含量过高、过低、或分布异常可能意味的测序质量问题可以通过异常值处理解决。
2. 由于男胎孕妇的 BMI 是影响胎儿 Y 染色体浓度的最早达标时间的主要因素，因此在以 BMI 为依据的分组中，每一组的最早达标时间有一个比较统一的趋势。
3. 男胎 Y 染色体浓度达标时间受多种因素的影响，根据这些因素进行 BMI 分组，每一组中的 Y 染色体浓度达标时间有一个比较统一的趋势。

4. X 染色体浓度在达到一定阈值后，则可认为 NIPT 的结果是基本准确的。

四、符号说明

符号	说明	单位
r_s	两个变量之间的 Spearman 相关系数	—
p_i	第序号 i 条数据胎儿检测健康的概率	—
x_{i1}	第序号 i 条数据胎儿的检测孕周	周
x_{i8}	第序号 i 条数据胎儿的 Y 染色体浓度	—
θ	优化模型中的惩罚因子	—
τ	不同 BMI 分组下检孕周数的调整因子	—
P_i	第序号 i 条数据胎儿检测准确度	—
z_i	第序号 i 条数据胎儿的 X 染色体浓度	—

五、问题一的建立与求解

本节首先通过针对男胎 NIPT 数据开展预处理，为后续相关性分析提供了准确、规范的数据集。随后通过筛选具有分析意义的指标，结合数据分布特性选择 Spearman 相关系数，量化胎儿 Y 染色体浓度与孕妇孕周数、BMI 等指标的关联程度，并通过对相关系数的显著性进行检验，利用 P 值对相关系数进行显著性检验。最后通过可视化分析数据分布，明确了 Y 染色体浓度与各指标的关联特性，完成了对 Y 染色体浓度与孕妇关键指标相关特性的分析、关系模型构建及显著性验证。




图 1: 问题一的流程图

5.1 数据预处理

问题一要求分析 Y 染色体浓度与孕妇孕周数和 BMI 等指标的相关性，本问题运用的是附件中的男胎检测数据，为了提高相关性分析的准确性，本文首先对数据进行必要性的处理。

5.1.1 异常值处理

针对附件中的男胎检测数据，在检测孕周方面，我们发现附件数据中存在书写错误的情形，小写 w 误写为大写 W，因此我们进行了相关更正，确保数据表达的正确性。对于附件中其他数值型数据，我们采用了 3σ 异常值识别的方法，对于每一个指标的异常值进行了剔除。

5.1.2 缺失值处理

针对附件中的数据，我们注意到末次月经一栏，在部分孕妇的数据中存在缺失的情况，因为末次月经可以通过检测日期与检测孕周的差值进行估算，因此我们运用此计算公式对数据进行了填充。

5.1.3 合理性处理

由题目背景介绍，我们知道通常孕妇的孕期在 10 周 25 周之间可以检测胎儿性染色体浓度，因此为了确保关系性分析的准确性，我们对检测孕周不满足要求的数据进行了剔除处理。为了适当减少分析工作的繁琐性，我们将怀孕次数和生产次数进行了结合处理，定义新变量未成功完成足月分娩的妊娠次数为两者的差值，来进行后续的分析处理。

5.1.4 量化处理

对于分类型变量，包括 IVF 妊娠、染色体的非整倍体、胎儿是否健康，我们用数值替代表示，从而方便后续的关系性分析，IVF 妊娠中 IUI（人工授精）记为 1，IVF（试管婴儿）记为 2，自然受孕记为 3；染色体的非整倍体中，无异常记为 1，异常为 0；胎儿健康为 1，不健康为 0。对于检测孕周，为了方便数值分析，我们依据天数在一周中的占比将检测孕周转化为以周为单位的变量。

5.2 Y 染色体与其他指标相关性分析

为了分析 Y 染色体浓度与其余指标的相关性，我们首先对于附件中的指标进行了筛选，选取了具有相关性分析意义的变量，如检测日期等，我们进行了筛选，本文分析的指标除 Y 染色体浓度外包括年龄、身高、体重、IVF 妊娠、检测孕周、孕妇 BMI、原始读段数、在参考基因组上比对的比例、重复读段的比例、唯一比对的读段数、GC 含

量、13, 18, 21 号染色体的 Z 值和 GC 含量、X,Y 染色体的 Z 值、X 染色体浓度、被过滤掉读段数的比例、染色体的非整倍体、未成功完成足月分娩的妊娠次数。

5.2.1 相关系数的运用

为了分析指标之间的相关性特性, 本文采取相关系数的方式刻画指标相关性, 建立指标关系模型。

Spearman 相关系数适用于不满足正态分布数据的相关性度量, 可以实现等级化变量之间的相关性; Pearson 相关系数适用于满足正态分布数据的相关性度量。由于我们选取的指标数据为连续型数据且不一定满足正态分布, 因此本文针对分布情况不同数据分别采用 Spearman 相关系数和 Pearson 相关系数分析 Y 染色体与各指标的相关性分析。

设 X、Y 为两组满足独立同分布的数据, 其样本个数为 n, X_i 、 Y_i 分别表示两组变量中的第 i 个变量的数值, 对两组数据同时进行降序或者升序排列, 得到两组数据的排序集合 x、y, x_i 、 y_i 为在各自集合中的排序。设 d_i 为 X, Y 集合中相同位元素排序之差, 由此我们得到 Spearman 相关系数 r_s 的计算公式:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)} \quad (1)$$

而对于 Pearson 相关系数, 设两组数据的均值分别为 $\bar{X}$ 、 $\bar{Y}$, 可以给出计算公式为:

$$r_p = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}} \quad (2)$$

由此我们可以实现对胎儿 Y 染色体浓度与孕妇的孕周数、BMI 等指标相关性的分析。

5.2.2 相关系数的检验

为了提高相关性分析的可信度, 本文接下来对相关系数的显著性进行检验, 以 Spearman 相关系数为例, 原假设 H_0 : Spearman 相关系数 $r_s \neq 0$ 备择假设 H_1 : Spearman 相关系数 $r_s = 0$ 显著性水平 α 设定为 0.05, 运用相关系数的 P 值即可判定显著性。

5.3 结果分析

首先为了选定适用的相关系数, 并且初步研究数据的分布情况, 我们对于上述所研究的各个数据的分布进行了研究, 受限于篇幅, 下面对于部分数据的分布情况进行了展示, 其余数据分布的详细情况可见附录。




图 2: 部分数据的分布情况

如上图展示，本文注意到 Y 染色体浓度的分布有所偏离正态，孕妇 BMI 呈现一个偏左的分布形态，而 X 染色体浓度，X、Y 染色体 Z 值，13、18、21 号染色体的 Z 值基本符合正态分布要求，对于其他数据，部分数据接近满足正态性分布，而部分数据有所偏离正态，因为本问题要求研究的是变量总体的相关性，样本量大，因此为了关系性分析的稳健性，本文综合考虑运用 Spearman 相关系数进行相关性分析。

本文使用 SPSSAU 在线计算平台进行 Spearman 相关系数计算和显著性检验，结果可视化如下 [3, 4]:




图 3: 其他因素与 Y 染色体浓度的 Spearman 相关性热力图

对于年龄、身高、体重、孕妇 BMI、原始读段数、在参考基因组上比对的比例、13 号染色体 Z 值、18 号染色体 Z 值、X 染色体 Z 值、13 号染色体 GC 含量、18 号染色体 GC 含量、未成功完成足月分娩的妊娠次数，Y 染色体浓度与上述指标呈现显著的负相关关系，其中与体重、孕妇 BMI、在参考基因组上比对的比例、18 号染色体的 Z 值呈现较强的负相关性。以孕妇 BMI 和 18 号染色体的 Z 值为例，Y 染色体浓度和孕妇 BMI 之间的相关系数值为-0.160，并且呈现出 0.01 水平的显著性；Y 染色体浓度和 18 号染色体的 Z 值之间的相关系数值为-0.176，并且呈现出 0.01 水平的显著性。

对于检测孕周、重复读段的比例、Y 染色体的 Z 值、X 染色体浓度、被过滤掉读段数的比例、染色体的非整倍体，Y 染色体浓度与上述指标呈现显著的正相关关系，其中与 Y 染色体的 Z 值、X 染色体浓度呈现较强的正相关性。以检测孕周、X 染色体浓度为例如，Y 染色体浓度和检测孕周之间的相关系数值为 0.064，并且呈现出 0.05 水平的显著性；Y 染色体浓度和 X 染色体浓度之间的相关系数值为 0.447，并且呈现出 0.01 水平的显著性。

对于 IVF 妊娠、唯一比对的读段数、GC 含量、21 号染色体的 Z 值、21 号染色体的 GC 含量，Y 染色体浓度与上述指标并没有相关关系。以 IVF 妊娠、GC 含量为例，Y 染色体浓度和 IVF 妊娠之间的相关系数值为 0.004，接近于 0，并且 p 值为 0.904>0.05；Y 染色体浓度和 GC 含量之间的相关系数值为-0.046，接近于 0，并且 p 值为 0.159>0.05。

六、 问题二的建立与求解

本节首先基于问题一预处理后的男胎 NIPT 数据，采用 K-Means++ 聚类算法，结合轮廓系数 (SI)、戴维森堡丁指数 (DBI)、卡林斯基 - 哈拉巴斯指数 (CHI) 并赋予权重计算综合评价得分，最终确定最优簇数为 3，对应 BMI 区间分别为 [26,31)、[31,35)、[35,41)。随后为实现“孕妇潜在风险最小”的目标，先通过 Logistic 回归构建胎儿不健康概率模型，再引入孕周惩罚函数、Y 染色体浓度调整函数，以“胎儿不健康概率 + 孕

周惩罚值 + 浓度调整值”最小化为目标，采用序列最小二乘规划法（SLSQP）求解约束优化问题，得出三组最佳时点分别为 16.7 周（16w+5）、17.2 周（17w+1）、18.1 周（18w+1）。最后通过两类检测误差分析验证结果稳健性解决了结果可靠性与抗干扰能力验证的问题。




图 4: 问题二的流程图

6.1 BMI 的合理分组

为了实现 BMI 的合理分组，本文考虑从问题一中已经筛选后的数据出发，以 BMI 作为分类依据，来实现数据中 BMI 的合理分组，由于分组会对后续问题 NIPT 节点的选择造成影响，因而与测序质量存在关联，本文预处理后的数据已经对 GC 含量的异常值进行了去除，很好地保证了测序结果的可靠性。

聚类分析 (K-Means) 是一种基于中心的无监督学习聚类算法 (K 均值聚类)，通过迭代，将样本分组成 k 个簇，使得每个样本与其所属类的中心或均值的距离之和最小 [5]。K-Means++ 算法是 K-Means 算法的拓展，在初始化簇中心时，摒弃了 K-Means 算法随机初始化的思想，其选择初始化聚类中心的原则是初始化簇中心之间的相互距离要尽可能地远，这样可以增加聚类结果的准确性 [6]。




图 5: K-Means++ 聚类示意图

因此，对于 BMI 分组这个无监督聚类问题，本文采用了 K-Means++ 聚类分析，通过孕妇 BMI 为依据，将数据分成多个簇，由此实现 BMI 的分组，为了检验聚类分析的合理性，本文综合采用了评价聚类的 3 个常用指标轮廓系数 (SI)、戴维森堡丁指数 (DBI) 以及卡林斯基-哈拉巴斯指数 (CHI) 来综合评价聚类分组的结果，下面简单介绍三个评价指标。

轮廓系数：对于单个样本 i ，设 x 是与它同类的其他样本的平均距离， y 是与它距离最近不同类别中样本的平均距离，则

$$SI(i) = \frac{y - x}{\max\{x, y\}} \quad (3)$$

而包含 n 个样本的总体轮廓系数为

$$SI = \frac{1}{n} \sum_{i=1}^n SI_i \quad (4)$$

轮廓系数越大，表示类的内部越紧凑，不同类的距离越大，聚类效果越好。

戴维森堡丁指数：该指标计算任意两类的类内距离平均之和除以这两类的中心距离，并求最大。假设一共有 n 个类别，则该指标具体定义如下：

$$DBI = \frac{1}{n} \sum_{k=1}^n \max_{k \neq m, m \in [1, n]} \frac{\sigma_k + \sigma_m}{d(c_k, c_m)}, \quad (5)$$

其中： σ_k 为第 k 类样本到其类中心的平均欧氏距离； $d(c_k, c_m)$ 为第 k 类和第 m 类的类中心之间的欧氏距离。DBI 值越小，说明分散程度越低，聚类效果越好。

卡林斯基-哈拉巴斯指数该指标通过评估类间方差和类内方差来计算聚类得分，假设数据集有 n 个样本，共分为 m 个类别，则该指标具体定义为：

$$\text{CHI} = \frac{\text{Tr}(B_m)}{\text{Tr}(W_m)} \times \frac{n - m}{m - 1}, \quad (6)$$

其中： B_m 是组间离散矩阵，即不同簇之间的协方差矩阵； W_m 是簇内离散矩阵，即一个簇内数据的协方差矩阵；Tr 表示矩阵的迹。CHI 越高，表示组内离散程度越小，组间离散程度越大，聚类效果越好。

为更合理地结合这 3 个指标对聚类效果进行客观的评价，这里参考相关文献来给各指标赋予不同的权重，得到最后聚类结果的综合评价得分。

6.2 最佳 NIPT 时点判断

为了使孕妇可能的潜在风险最低，在这里本文尽可能地考察所有与风险相关的因素，首先最相关的就是胎儿的检测健康情况，在附录中对应的是染色体的非整倍体，可以视为是一个 0-1 变量，若检测出则认为有问题定义值为 0，反之定义值为 1。由于根据临床经验，畸型胎儿三种体征分别由胎儿 13 号、18 号和 21 号染色体浓度是否异常决定，因此为了更准确地刻画胎儿健康情况，我们运用 Logistic 回归，以胎儿 NIPT 健康情况为因变量，记第序号 i 数据胎儿检测健康的概率为 p_i ，检测孕周、13 号、18 号、21 号染色体 Z 值和 GC 含量，Y 染色体浓度为自变量，记第序号第 i 条数据的上述指标分别为 $x_{i1}, x_{i2}, \dots, x_{i8}$ 建立回归模型如下：

$$\ln \left(\frac{p_i}{1 - p_i} \right) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \beta_3 x_{i3} + \beta_4 x_{i4} + \beta_5 x_{i5} + \beta_6 x_{i6} + \beta_7 x_{i7} + \beta_8 x_{i8} \quad (7)$$

利用最大似然估计法即可求解出回归方程中的参数，本文定义 q_i 为相应第序号 i 数据胎儿不健康的概率，即 $q_i = 1 - p_i$ 。

第二，因为要求实际中应尽早发现不健康的胎儿，早期发现（12 周以内）风险较低；中期发现（13 - 27 周）风险高；晚期发现（28 周以后）风险极高，依据这样一种关系，我们对于检测周数给予一个惩罚函数的设置。

$$L(x_{i1}) = \begin{cases} \mathcal{A}(\eta\theta_A x_{i1}) & 10 \leq x_{i1} \leq 12 \\ \mathcal{A}(\eta\theta_B x_{i1}) & 13 \leq x_{i1} \leq 27 \\ \mathcal{A}(\eta\theta_C x_{i1}) & x_{i1} \geq 28 \end{cases} \quad (8)$$

其中， θ_A 、 θ_B 、 θ_C 表示惩罚强度的因子，其取值越大，惩罚就越大。本文约定对于一周如果超过四天的则认为属于下一周，反之仍属于这一周。 $\mathcal{A}(x) = \frac{1}{1+e^{-x}}$ 为 sigmoid 函数。本文选择的惩罚因子为：

$$\theta_A = 0.01, \theta_B = 0.03, \theta_C = 0.05$$

此外考虑到不同 BMI 分组下，检孕周数不同的风险也会有所差异，因此我们引入参数 η ，BMI 分组由低到高参数值分别为 0.7、1.2、1.5。

最后，男胎孕妇的 BMI 是影响胎儿 Y 染色体浓度的最早达标时间的主要因素，因此在此之前以 BMI 为依据的分组中，每一组的最早达标时间应有一个比较统一的趋势。本文选取每一组中胎儿 Y 染色体浓度已经达标的样本，统计这些样本检测孕周数的分布状况，可以认为此时这样样本的检测孕周数应为最早达标时间，记这个样本的下四分位数为 m_j ，上四分位数为 M_j ，那么我们给出以下模型：

对于检测孕周数位于 (m_j, M_j) 范围内的检孕周数，我们有调整函数，其中 $\mathcal{A}(x) = \frac{1}{1+e^{-x}}$ 为 sigmoid 函数：

$$\delta = \begin{cases} \mathcal{A}(0.05\tau x_{i1}) & x_{i8} < 0.04 \\ -\mathcal{A}(0.03\tau x_{i1}) & x_{i8} \geq 0.04 \end{cases} \quad (9)$$

对于检测孕周数不在上述范围内的检孕周数，我们有调整函数：

$$\delta = \begin{cases} \mathcal{A}(0.03\tau x_{i1}) & x_{i8} < 0.04 \\ -\mathcal{A}(0.05\tau x_{i1}) & x_{i8} \geq 0.04 \end{cases} \quad (10)$$

类似惩罚函数的考虑，在不同 BMI 分组下，检孕周数不同的风险也会有所差异，因此我们引入参数 τ ，BMI 分组由低到高参数值分别为 0.8、1.1、1.5。

此外由于男胎的 Y 染色体浓度达到或高于 4% 才可认为 NIPT 的结果是基本准确的，所以我们依据 Y 染色体浓度对于胎儿不健康概率做一个调整：

$$\tilde{q}_i = \begin{cases} q_i + 0.05 & x_{iB} < 0.04 \\ q_i & x_{iB} \geq 0.04 \end{cases} \quad (11)$$

记 $x_k^{\min}$ 和 $x_k^{\max}$ 分别为筛选后该数据的最小值和最大值，为了保证结果数据的合理性，我们约定各指标应该在已知附件数据的最小值和最大值之间。特别地，对于检孕周数，因为希望检孕周数集中于该簇检孕周数分布中间位置，从而保证测序质量的准确性，因此本文给出优化模型如下，检孕周数 x_1 为决策变量。

$$\begin{aligned} & \min \quad \tilde{q} + L(x_1) + \delta \\ & \text{s.t.} \quad \begin{cases} 10 \leq x_1 \\ x_k^{\min} \leq x_k \leq x_k^{\max}, \quad k = 2, 3, 4, 5, 6, 7, 8 \\ m_j \leq x_1 \leq M_j \end{cases} \end{aligned} \quad (12)$$

该问题为约束优化问题，经试验本文最终选择序列最小二乘规划法 (Sequential Least Squares Programming, 缩写为 SLSQP) 进行求解。该方法的求解原理如下：




图 6: SLSQP 算法求解流程

6.3 检测误差影响分析

由于在实际检测中, 经常会出现测序失败, 如检测时点过早和不确定因素影响等的情况。因此本文认为第一类检测误差为检测孕周、Y 染色体浓度等与检测相关的原始数据存在误差的情况, 为了考虑这种误差的情况, 我们对于预处理后的上述数据分别添加均值为 0、方差不同的高斯噪声 $\varepsilon_1, \varepsilon_2, \varepsilon_3$, 其中, $\varepsilon_1 \sim Normal(0, 0.1^2)$, $\varepsilon_2 \sim Normal(0, 0.5^2)$, $\varepsilon_3 \sim Normal(0, 1^2)$, 观察 BMI 的合理分组和最佳 NIPT 时点判断是否会存在差异。

从附件中的数据, 我们发现 NIPT 的检测结果与最终实际胎儿的健康情况在部分样本上存在差异, 因此第二类检测误差为 NIPT 检测结果有误的情况, 我们将这一类检测结果有误的情况分别包含和不包含在其它检测无误的情况组成数据集, 来观察这对于 BMI 合理分组和最佳 NIPT 时点的判断是否会存在差异。

6.4 结果分析

6.4.1 BMI 的合理分组

根据 K-Means++ 的聚类结果, 最优簇数为 $k=3$, 根据假设检验各簇之间的差异性明显, 符合要求, 其中组 1 孕妇 BMI 范围为 $[26, 31)$, 组 2 孕妇 BMI 范围为 $[31, 35)$, 组 3 孕妇 BMI 范围为 $[35, 41)$ 。




图 7: 聚类效果可视化

为了对聚类的结果进行合理性分析，我们计算了不同聚类数的综合评价得分，结果显示 $k=2$ 时，得分为 0.400； $k=3$ 时，得分为 0.709； $k=4$ 时，得分为 0.366，因此这佐证了本文 BMI 分组的合理性，提高了聚类的可靠性。




图 8: 不同聚类数得分情况

6.4.2 最佳 NIPT 时点判断

对于 BMI 分组后的三组，本文运用序列最小二乘规划法进行了优化问题的求解，结果显示，对于组 1 孕妇 BMI 范围为 $[26,31)$ 来说，最佳 NIPT 时点为 16.7 周即约

表 1: 各 BMI 分组对应的最佳 NIPT 检测时点

BMI 分组	BMI 范围 (kg/m ²)	最佳 NIPT 时点 (周)	最佳 NIPT 时点 (孕周表述)
组 1	[26, 31)	16.7	16w+5
组 2	[31, 35)	17.2	17w+1
组 3	[35, 41)	18.1	18w+1

为 16w+5; 对于组 2 孕妇 BMI 范围为 [31,35) 来说, 最佳 NIPT 时点为 17.2 周即约为 17w+1; 对于组 3 孕妇 BMI 范围为 [35,41) 来说, 最佳 NIPT 时点为 18.1 周即约为 18w+1。由此可知, 三个组最终的最佳 NIPT 时点均在各组 Y 染色体达标时间之后, 也就意味着此时检测结果是可信的, 而且三个时点均处于中期风险内, 由于早期发现往往并不能保证 NIPT 检测的可靠性, 因此时点落于中期发现范畴是合理的, 本文还注意到 BMI 越高, 相应的 NIPT 时点越后, 这与 BMI 影响 Y 染色体达标时间和浓度的规律相符, 此外根据优化模型, 最佳 NIPT 时点已经综合考虑了各种潜在的风险, 解释性较强。

6.4.3 检测误差影响分析

首先对于第一类误差检测误差来说, 在添加高斯噪声之后, 聚类仍显示分成三组为最优, 组 1、组 2 和组 3 的 BMI 范围没有变化, 组 1 和组 3 的最佳 NIPT 时点没有变化, 组 2 的最佳 NIPT 时点变为了 18.1 周; 在添加高斯噪声之后, 聚类 and BMI 分组的情况和添加高斯噪声添加下的情况相同, 组 1 和组 2 的最佳 NIPT 时点没有变化, 组 3 的最佳 NIPT 时点变为了 17.7 周; 在添加高斯噪声之后, 结果与添加高斯噪声之后情况相同。




图 9: 不同高斯噪声下的最佳 NIPT 时点

由此我们可以证明我们分组结果和最佳 NIPT 时点结果的稳健性, 第一类误差对结果的影响较小。

表 2: 第二类误差对比结果

BMI 分组	BMI 范围 (kg/m ²)	最佳检测孕周
组 1	26.62-31.48	16.7
组 2 (原始数据)	31.53-34.87	17.2
组 2 (第二类误差处理后)	31.53-34.79	18.5
组 3	34.90-41.13	18.1

对于第二类误差检测结果有误来说, 结果显示最优聚类数仍为 3, BMI 分组范围相同, 但是此时由于只有组 2 仍含有检测结果显示异常的数据, 因此只能以组 2 为例检验最佳 NIPT 时点的情况, 结果显示最佳 NIPT 时点变为了 18.5 周, 与之前结果有小范围的变化不过相对来说仍在接受范围内。

因此可以得出结论第二类检测误差对于分组结果无影响, 受限于已有数据, 误差对于最佳 NIPT 时点存在影响但较小, 仍可以接受。

七、 问题三的建立与求解

本节首先通过灰色关联分析筛选出对男胎 Y 染色体浓度达标时间影响较大的六大核心因素 (体重、孕妇 BMI、原始读段数、唯一比对读段数、X 染色体浓度、被过滤读段数比例), 随后结合筛选出的影响因素与 BMI 指标, 采用 K-Means++ 聚类算法, 确定最优簇数为 2, 划分 BMI 区间为 [26,33) 与 [33,41)。Y 染色体浓度达标比例, 针对性制定 NIPT 时点判定策略: 高比例组直接沿用问题二的 “Logistic 回归 + 孕周惩罚函数 + 浓度调整函数 + 序列最小二乘规划法 (SLSQP)” 求解; 低比例组先通过随机森林筛选可信数据再应用上述方法, 最终得出 [26,33) 组最佳时点 16.9 周 (16w+6)、[33,41) 组最佳时点 19.8 周 (19w+6)。

最后通过两类检测误差分析验证结果可靠性: 对检测孕周、Y 染色体浓度等数据添加不同方差高斯噪声 (第一类误差), 结果显示 BMI 分组无变化, 最佳时点波动较小; 纳入或排除 NIPT 检测错误样本 (第二类误差), 对于大 BMI 的组来说, NIPT 检测结果的准确性影响较大。




图 10: 问题三流程图

7.1 BMI 合理分组

7.1.1 Y 染色体浓度达标时间影响因素筛选

根据题意，男胎 Y 染色体浓度达标时间受到多种因素的影响，为了考量这些因素对于 Y 染色体浓度的影响大小，从而筛选出影响较大的因素，便于后续 BMI 合理分组。

灰色关联分析是指对一个系统发展变化态势的定量描述和比较的方法，其基本思想是通过确定参考数据列和若干个比较数据列的几何形状相似程度来判断其联系是否紧密，它无需严格满足数据正态分布假设，对样本量要求低（少量数据即可分析），计算过程相对简便。因此由于去除不达标 Y 染色体浓度减少了一定量的数据，本文此处采用灰色关联分析来考量 Y 染色体浓度达标时间与其他因素的关系，下面本文简单介绍灰色关联分析的数学原理 [7]。

Step1: 确定特征数列和母数列

比较序列为，即各个要研究相关性的因变量：

$$\begin{bmatrix} \mathbf{X}'_1 & \mathbf{X}'_2 & \cdots & \mathbf{X}'_n \end{bmatrix} = \begin{bmatrix} x'_1(1) & x'_2(1) & \cdots & x'_n(1) \\ x'_1(2) & x'_2(2) & \cdots & x'_n(2) \\ \vdots & \vdots & & \vdots \\ x'_1(m) & x'_2(m) & \cdots & x'_n(m) \end{bmatrix} \quad (13)$$

母序列（即评价标准）为：

$$\mathbf{X}'_0 = (x'_0(1), x'_0(2), \cdots, x'_0(m))^T \quad (14)$$

Step2: 数据量纲统一化

对指标数据进行量纲统一化。为了真实地反映实际情况，排除由于各个指标单位的不同及其数值数量级间的悬殊差别带来的影响，避免不合理现象的发生，需要对指标进行量纲统一化处理。

Step3: 计算关联系数

由下式分别计算每个比较序列与参考序列对应元素的关联系数：

$$\gamma(x_0(k), x_i(k)) = \frac{\Delta \min + \rho \Delta \max}{\Delta_{ik} + \rho \Delta \max} \quad (15)$$

其中， $\Delta \min = \min_i \min_k |x_0(k) - x_i(k)|$ ； $\Delta \max = \max_i \max_k |x_0(k) - x_i(k)|$ ； $\Delta_{ik} = |x_0(k) - x_i(k)|$ ； $\rho \in (0, 1)$ 为分辨系数，分辨系数越小，关联系数间差异越大，一般取 0.5。

Step4: 计算关联序度

分别计算其各个指标与参考序列对应元素的关联系数的加权平均值，以反映各操纵装置对象与参考序列间的关联关系，并称其为关联度，记为 r_{0i} ，计算公式如下：

$$r_{0i} = \frac{1}{m} \sum_{k=1}^m W_k \zeta_i(k) \quad (16)$$

Step5: 分析计算结果

根据灰色加权关联度的大小，建立各评价对象的关联序。关联度越大，表明评价对象对评价标准的重要程度越大。

7.1.2 聚类分组研究

为了实现 BMI 的合理分组，让各组都有一个较为集中的 Y 染色体浓度达标时间，本文选择 BMI 和前面筛选出来的对 Y 染色体浓度达标时间有较大影响的因素作为聚类标准，以此对男胎孕妇的 BMI 实现合理分组。由于本问题仍为一个无监督聚类问题，本文仍采用 K-Means++ 聚类算法和综合聚类评价指标来进行聚类结果的计算和评价。

7.2 NIPT 时点判定

7.2.1 统计 Y 染色体浓度达标比例情况

为了考量 Y 染色体浓度达标比例的影响，本文先对上述 BMI 分组后的各组进行 Y 染色体浓度达标比例的计算，从而将各组划分为 Y 染色体浓度达标率高的组和 Y 染色体浓度达标率低的组，从而分别采用不同的 NIPT 时点判定方法。


7.2.2 Y 染色体浓度达标比例高的组时点判定方法

对于 Y 染色体浓度达标率高的组，本文认为这个组的检测结果是可信的，因此采用问题二相同的 NIPT 时点判定方法，也就是建立 Logistic 回归模型、建立惩罚函数和调整函数，从而构建优化模型选出最恰当的 NIPT 时点。

7.2.3 Y 染色体浓度达标比例低的组时点判定方法

对于 Y 染色体浓度达标率低的组，本文认为这个组的检测结果准确性存在不确定性。因此需要对于检测结果进行检验，本文选取组中 Y 染色体浓度达标的数据，作为训练集并评估模型性能，再对其余 Y 染色体浓度不达标的数据进行预测，由于随机森林能有效降低过拟合风险、对数据预处理要求低，且鲁棒性强、兼顾预测性能与落地效率，因此本文使用了随机森林的方法对训练集进行训练，再在其余 Y 染色体浓度不达标的数据中进行预测，对于预测结果与检测结果相符的数据，本文进行保留，反之进行筛除，认为该数据存在误差 [8]。

图 11: 随机森林示意图



对于剩下的经检验检测结果可信的数据，再采用问题二相同的 NIPT 时点判定方法，即建立 Logistic 回归模型、建立惩罚函数和调整函数，从而构建优化模型选出最恰当的 NIPT 时点。

7.3 检测误差影响

由于本问题面临的误差与问题二相同，均可以归结为第一类误差：原始数据误差；第二类误差：NIPT 结果有误，因此本文此处仍对这两种误差的影响进行考虑。

7.4 结果分析

7.4.1 BMI 合理分组

(1) Y 染色体浓度达标时间影响因素筛选

表 3: 与 Y 染色体浓度达标时间关联度结果

评价项	关联度	排名
X 染色体浓度	0.878	1
唯一比对的读段数	0.868	2
原始读段数	0.867	3
体重	0.866	4
被过滤掉读段数的比例	0.863	5
孕妇 BMI	0.862	6
...	...	...
Y 染色体的 Z 值	0.754	21
X 染色体的 Z 值	0.691	22

本文使用 SPSSAU 平台进行灰色关联分析计算，结果如上 [3, 4]。由结果可知，很多指标数据都对 Y 染色体浓度达标时间存在影响，本文选取了影响较大的前六个指标，相关系数均在 0.86 以上，可以认为均与 Y 染色体浓度达标时间有很大关系，分别为体重、孕妇 BMI、原始读段数、唯一比对的读段数、X 染色体浓度、被过滤掉读段数的比例，本文选定这六个因素进行后续的聚类分析。

(2) 聚类分组研究




图 12: BMI 聚类结果

结果显示，BMI 分组为两组是最优的，聚类评价得分为 0.7，高于 K=3 的聚类得分 0.6858 和 K=4 的聚类得分 0.4316，而对于这两组来说，经过对组内 BMI 数值分布的研究，确定了 BMI 分组区间分别为 [26,33) 和 [33,41)。由于本问中考虑男胎 Y 染色体浓度达标时间受多种因素影响，因此相比之前的分组结果，所得分组结果数变少，代表事实上 BMI 分成两组即可根据孕妇的不同情况确定最佳 NIPT 时点。

表 4: 第三问基础分类结果

核心指标	组 1	组 2
总样本数	621	335
聚类占比	65.0% (621/956)	35.0% (335/956)
BMI 最小值 (kg/m^2)	26.6193	33.0108
BMI 最大值 (kg/m^2)	32.9699	41.1328
BMI 平均值 (kg/m^2)	30.6256	35.0757
BMI 标准差 (kg/m^2)	1.3483	1.7915
分类边界	最大 BMI: 32.9699 最小 BMI: 33.0108	

7.4.2 NIPT 时点判定

(1) 统计 Y 染色体浓度达标比例情况

经计算,对于分组的两组来说,BMI 分组区间为 [26-33) 的 Y 染色体浓度达标比例为 91.14%,BMI 分组区间为 [33-41) 的 Y 染色体浓度达标比例为 83.5%,因此我们对于 BMI 分组区间为 [26-33) 的组直接采用与问题二中 NIPT 时点判定方法,而对于 BMI 分组区间为 [33-41) 的组,本文则先检验检测结果筛选数据,再采用问题二中的 NIPT 时点判定方法。




图 13: Y 染色体浓度达标比例情况

(2) NIPT 时点判定方法

对于 BMI 分组区间为 [26-33) 的组来说,本文先使用随机森林模型检验检测结果,训练结果显示模型判断准确率为 98%,可信度高,训练好的模型在测试集中筛除了六条检测有误的结果,进一步增加了模型结果的可靠性。优化模型结果显示最佳 NIPT 时点为 16.9 周即 16w+6,这与之前所得对于小 BMI 组所得的最佳 NIPT 时点结果差异较小,进一步佐证了我们结果的合理性。




图 14: 随机森林预测效果




图 15: 随机森林训练结果

对于 BMI 分组区间为 [33-41) 的组来说, 结果显示最佳 NIPT 时点为 19.8 周即 19w+6, 相比之前 BMI 较大的组来说检测时点有所后退, 可以认为此时 Y 染色体浓度达标比例更高, 检测结果可信性更强, 从而更加有利于减少孕妇生育的潜在风险。

7.4.3 检测误差影响

首先对于第一类误差检测误差来说, 添加高斯噪声 $\varepsilon_1, \varepsilon_2, \varepsilon_3$ 后两个分组的结果显示 BMI 分组并没有明显改变, 而在最佳 NIPT 时点方面, BMI 分组区间为 [26, 33) 的组时点分别为 16.5 周, 17 周和 17 周, BMI 分组区间为 [33, 41) 的组时点分别为 20 周,

表 5: 问题三检测误差影响对比结果

分组	原始预测时点	方差 0.1	方差 0.5	方差 1	第二类误差的
0	16.9	16.5	17	17	1
1	19.8	20	19.7	20.4	19.6

19.7 周和 20.4 周，由此可知检测时点的变化较小。综上第一类检测误差对于结果的影响较小，论证了我们结果的稳健性。

其次对于第二类检测误差来说，两个分组的结果显示 BMI 分组和最佳 NIPT 时点并没有明显改变。

八、 问题四模型的建立与求解

本节首先通过对女胎 NIPT 原始数据开展系统性预处理，解决了原始数据中存在的异常、缺失、不可信及变量类型不统一等质量缺陷，为后续分析奠定数据基础。

随后通过随机森林模型，依托“Mean Decrease Accuracy”与“Mean Decrease Gini”两大指标，量化评估各因素对女胎异常的影响程度，筛选出年龄、13 号染色体 GC 含量、18 号染色体 GC 含量、被过滤读段数比例、21 号染色体 GC 含量、X 染色体浓度六大核心影响因素，明确了判定分析的核心指标。

最后通过设定深度为 6 的决策树模型，生成 5 条包含具体指标阈值与对应女胎异常概率的判定规则，结合异常概率对比选定方法三（年龄 > 32.5 、被过滤读段数比例 < 0.021 、13 号染色体 GC 含量 > 0.373 ，异常概率 0.161）与方法四（年龄 > 25.5 、13 号染色体 GC 含量 > 0.373 、被过滤读段数比例 > 0.021 、X 染色体浓度 < -0.016 ，异常概率 0.093）作为最终判定方法；同时通过十折交叉检验验证模型稳健性。




图 16: 问题四的流程图

8.1 数据预处理

本问用到的是附录中关于女胎的检测数据，为了确保分析的结果的准确性，本文首先对数据进行必要性的预处理。

8.1.1 异常值处理

针对附件中的女胎检测数据，本文采用了 3σ 异常值识别的方法，对于每一个指标的异常值进行了剔除。

8.1.2 缺失值处理

针对附件中的女胎检测数据，本文注意到末次月经一栏，在部分孕妇的数据中存在缺失的情况，因为末次月经可以通过检测日期与检测孕周的差值进行估算，因此本文运用此计算公式对数据进行了填充。

8.1.3 合理性处理

由题目背景介绍，本文知道通常孕妇的孕期在 10 周 25 周之间可以检测胎儿性染色体浓度，因此为了确保分析的准确性，本文也对检测孕周不满足要求的数据进行了剔除处理。此外为了适当减少分析的繁琐性，本文依然将怀孕次数和生产次数进行了结合处理，定义新变量未成功完成足月分娩的妊娠次数为两者的差值，来进行后续的分析处理。

此外由题意可知如果女胎的 X 染色体浓度没有异常，则可认为 NIPT 的结果是基本准确的，因此本文认为有必要先筛选出准确结果的数据项。

定义新变量检测准确度，记为 P_i ，记染色体非整倍体无异常与胎儿健康相符的数据项的检测准确度为 1，反之为 0。以检测准确度为因变量，X 染色体浓度为自变量，记为 z_i ，建立 Logistic 回归，方程如下：

$$\ln \frac{P_i}{1 - P_i} = \beta_0 + \beta_1 z_i \quad (17)$$

本文依据相关文献给予检测准确度一个阈值，此处设定为 80%，由此代入方程求解出 X 染色体浓度的阈值，对于超过 X 染色体浓度阈值的数据本文予以保留，反之筛除。

8.1.4 量化处理

针对分类型变量，包括 IVF 妊娠、染色体的非整倍体、胎儿是否健康，本文用数值量化表示，从而方便后续的分析，IVF 妊娠中 IVF（试管婴儿）记为 1，自然受孕记为 2；染色体的非整倍体中，无异常记为 1，异常为 0；胎儿健康为 1，不健康为 0。对于检测孕周，为了方便数值分析，本文依据天数在一周中的占比将检测孕周转化为以周为单位的变量。

8.2 判定影响女胎异常的重要成分

由于女胎异常可能与多种因素相关，有些因素可能对于女胎异常的影响相比之下较小，因此为了选取出影响较大的因素，本文先采用随机森林模型中的两个重要指标“Mean Decrease Accuracy”和“Mean Decrease Gini”得分来衡量指标的重要性，其中，“Mean Decrease Accuracy”表示随机森林预测准确性的降低程度，“Mean Decrease Gini”计算了每个变量对分类树每个节点上观测值的异质性的影响。这两个指标的数值越大表示该成分的重要性越大，从而得到与女胎异常相关的主要成分。

8.3 量化确定判定女胎异常的方法

决策树通过“分割数据”生成规则，每个分割点本质就是一个“临界值候选”，无需复杂计算，本文为了具体确定这些重要成分对于女胎异常影响的阈值，从而给出判定女胎异常的方法，因此本文使用了决策树方法确定阈值，由于决策树易因噪声数据生成“虚假分割点”，为了确保计算结果的稳健性，本文后续进行了交叉验证。




图 17: 决策树示意图


8.4 结果分析

8.4.1 数据预处理


受限于篇幅限制，有关数据预处理的结果详见附录。本文此处特别说明关于 X 染色体浓度筛除数据的结果，经过计算，X 染色体浓度大于等于 -0.025380 时可以认为检测结果可信，对此本文筛除了 68 条检测结果有可能存疑的数据，对于剩下的数据准确度达到了 93.3%，可以认为基本满足检测结果可信性要求。

8.4.2 判定影响女胎异常的重要成分

经过在 Python 软件上使用随机森林模型进行计算，结果显示结合两个重要指标的数值，年龄、13 号染色体的 GC 含量、18 号染色体的 GC 含量、被过滤掉读段数的比例、21 号染色体的 GC 含量、X 染色体浓度的综合得分位于前六名，均达到 0.42 以上，由于注意到后面的因素评分下降幅度较大，因此只选择这六个因素作为影响女胎异常的重要成分，并绘制前 6 个重要特征的频数分布直方图，以可视化健康和 unhealthy 样本在各个特征上的分布差异。



(a) 指标重要性



(b) 指标分布特征

图 18: 指标详情可视化

8.4.3 量化确定判定女胎异常的方法

在 Python 中使用决策树模型进行分析时，我们综合考虑包含上述六个重要因素和叶子节点样本量大于 10 两个条件，最终确定将决策树深度设为 6。这一参数设置既能较完整包含所有关键影响因素，又能保证各叶子节点具有足够的样本代表性，从而更可靠地给出女胎异常的判定规则。模型结果显示，基于该参数构建的决策树共给出了五个女胎异常的判定方法：

决策树结构 - 基于重要特征的判定规则




图 19: 决策树结果

(1) 当年龄位于区间 $[21.5, 25.5]$ 内, 13 号染色体的 GC 含量大于 0.373, 且被过滤掉读段数的比例小于 0.025 时, 女胎出现异常的概率为 0.037;

(2) 当年龄位于区间 $[25.5, 32.5]$ 内, 13 号染色体的 GC 含量大于 0.373, 且被过滤掉读段数的比例小于 0.021 时, 女胎出现异常的概率为 0.055;

(3) 当年龄大于 32.5, 被过滤掉读段数的比例小于 0.021, 且 13 号染色体的 GC 含量大于 0.373 时, 女胎出现异常的概率为 0.161;

(4) 当年龄大于 25.5, 13 号染色体的 GC 含量大于 0.373 且被过滤掉读段数的比例大于 0.021, 且 X 染色体浓度小于 -0.016 时, 女胎出现异常的概率为 0.093;

(5) 当年龄大于 25.500, 13 号染色体的 GC 含量大于 0.373, 被过滤掉读段数的比例大于 0.021, 且 X 染色体浓度大于 -0.016, 女胎出现异常的概率为 0.004。

根据女胎出现异常概率的对比, 本文最终选定方法三和方法四作为女胎异常的判定方法。此外, 为了验证决策树模型的准确性, 本文还使用了十折交叉检验, 检验结果显示交叉验证准确率为 92.8%, 说明结果具有很高的可靠性, 可以接受。

九、模型的评价与推广

9.1 模型的评价

9.1.1 模型的优点

1. 本文的模型具有可靠性。本文在求解每个问题时, 对于已知数据均进行了数据预处理, 如缺失值处理、异常值处理、合理性处理 (依据背景知识要求) 等, 因此这为我们模型后续的结果可信性提供保障。

2. 本文的模型具有稳健性。本文对多个模型的结果进行了检验，如关系模型中本文对显著性进行了检验；在 BMI 合理分组问题上，本文对于聚类数的选择运用评价指标进行了合理性检验；在考虑检测误差的影响上，本文全面地考虑了第一类检测误差，使用不同的 Gauss 噪声进行模拟，第二类检测误差，考虑测序有误结果的影响，佐证了分析结果的合理性；在决策树模型中，本文进行了交叉验证检验合理性。
3. 本文的模型具有创新性。在 NIPT 时点判定上，本文创新性地引入了 Logistic 回归、惩罚函数、调整函数来构建优化模型，结果显示模型灵敏性良好；在女胎异常性判断上，本文创新性地结合了随机森林模型和决策树模型，各取所长，利用随机森林模型筛选重要特征，利用决策树模型给出最后女胎异常的判定方法，结果显示模型具有稳健性。
4. 本文的模型具有实践意义。本文模型的构建上始终遵循已知医学信息，例如 NIPT 的准确性主要由胎儿性染色体浓度判断、男胎 Y 染色体浓度达标时间受多种因素影响等，模型的结果为实际医学实践提供了一定的参考价值。

9.1.2 模型的缺点

1. 本文根据已知有关 Y 染色体浓度的达标时间影响因素作出了一定的理想化假设，因此可能与实际存在一定差异。
2. 本文受限于数据量大小，在第二类检测误差 NIPT 检测结果有误的分析上，由于只有一个组的数据出现此情况，因此对于第二类检测误差的分析具有一定局限性。
3. 本文受限于已知有关 NIPT 检测的相关信息，在最佳 NIPT 检测节点的优化模型建立上可能并没有考虑到全部可能的风险因素，与现实的 NIPT 检测情况存在一定误差。

9.2 模型的推广

若已知更加丰富的有关男胎和女胎的数据，还有有关 NIPT 研究的更多前沿信息，对于优化模型考虑孕妇潜在风险问题上可能考虑地更加全面，符合实际，同时对于两类检测误差的影响分析可以更加深入，使模型的结果实践意义更加深刻。

参考文献

- [1] 豆包，豆包专业版 V1.0，字节跳动（ByteDance），2025-09-05.
- [2] 豆包，豆包专业版 V1.0，字节跳动（ByteDance），2025-09-06.

- [3] The SPSSAU project (2025). SPSSAU. (Version 25.0) [Online Application Software]. Retrieved from <https://www.spssau.com>.
- [4] 周俊, 马世澎. SPSSAU 科研数据分析方法与应用. 第 1 版 [M]. 电子工业出版社,2024.
- [5] 杨俊闯, 赵超.K-Means 聚类算法研究综述 [J]. 计算机工程与应用,2019,55(23):7-14+63.
- [6] 付春龍, 盛腾. 常用聚类内部评价指标的对比分析 [J]. 电脑编程技巧与维护,2023,(04):3-5+9.DOI:10.16184/j.cnki.comprg.2023.04.001.
- [7] 付雅芳, 杨任农, 刘晓东, 等. 基于灰色关联分析的软件工作量估算方法 [J]. 系统工程与电子技术,2012,34(11):2384-2389.
- [8] 曹正凤. 随机森林算法优化研究 [D]. 首都经济贸易大学,2014.

附录

A 支撑材料列表

1. 源程序
2. 中间过程数据

B 源程序

源程序 1: 绘制数据分布的 Python 代码

```
import sys
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from PyQt5.QtWidgets import QApplication, QMainWindow, QWidget, QVBoxLayout,
    QPushButton, QFileDialog, QHBoxLayout
from matplotlib.backends.backend_qt5agg import FigureCanvasQTAgg as
    FigureCanvas
import matplotlib.font_manager as fm
import numpy as np

def setup_chinese_font():
    # 设置matplotlib中文字体
    font_list = fm.findSystemFonts(fontpaths=None, fontext='ttf')
    simhei_found = any('SimHei' in fm.FontProperties(fname=f).get_name() for f
        in font_list)
    if simhei_found:
        plt.rcParams['font.sans-serif'] = ['SimHei']
        plt.rcParams['axes.unicode_minus'] = False
    else:
        print("警告: 未检测到SimHei字体, 中文可能显示异常。建议安装SimHei字体。")
        plt.rcParams['font.sans-serif'] = ['Arial Unicode MS', 'Microsoft
            YaHei', 'STSong', 'Arial']
        plt.rcParams['axes.unicode_minus'] = False

def force_chinese_font(ax):
    # 强制所有文本对象使用SimHei字体
    for label in ax.get_xticklabels() + ax.get_yticklabels():
```

```

        label.set_fontname('SimHei')
    ax.title.set_fontname('SimHei')
    ax.xaxis.label.set_fontname('SimHei')
    ax.yaxis.label.set_fontname('SimHei')

class PlotWindow(QMainWindow):
    def __init__(self, fig):
        super().__init__()
        self.setWindowTitle('直方图与密度曲线')
        self.figure = fig
        self.canvas = FigureCanvas(self.figure)
        central_widget = QWidget()
        self.setCentralWidget(central_widget)
        vlayout = QVBoxLayout(central_widget)
        vlayout.addWidget(self.canvas)

        # 添加保存按钮
        hlayout = QHBoxLayout()
        self.save_btn = QPushButton("保存图片")
        self.save_btn.clicked.connect(self.save_figure)
        hlayout.addWidget(self.save_btn)
        hlayout.addStretch()
        vlayout.addLayout(hlayout)

        self.resize(900, 600)

    def save_figure(self):
        path, _ = QFileDialog.getSaveFileName(self, "保存图片", "", "PNG图片 (*.png);;JPEG图片 (*.jpg);;所有文件 (*)")
        if path:
            self.figure.savefig(path, dpi=300, bbox_inches='tight')
            print(f"图片已保存到: {path}")

def main():
    setup_chinese_font()
    file_path = input("请输入xls文件路径: ").strip()
    try:
        df = pd.read_excel(file_path)
    except Exception as e:
        print(f"文件读取失败: {e}")

```

```

return

print("\n可选列名如下: ")
for idx, col in enumerate(df.columns):
    print(f"{idx}: {col}")

while True:
    sel = input("\n请输入要绘制小提琴图的列序号（可多个，用空格分隔）: ")
    try:
        indices = [int(i) for i in sel.split()]
        if all(0 <= i < len(df.columns) for i in indices):
            break
        else:
            print("序号超出范围，请重新输入。")
    except:
        print("输入格式错误，请重新输入。")

cols = [df.columns[i] for i in indices]
data = df[cols]

# 颜色选择
COLOR_LIST = ['#0af676', '#00e0af', '#00c5e0', '#00a7fc', '#0083f8',
               '#0058d2']
print("\n可选颜色如下: ")
for idx, c in enumerate(COLOR_LIST):
    print(f"{idx}: {c}")
col_colors = []
for col in cols:
    while True:
        sel_color = input(f"请选择列 [{col}] 的颜色序号（0-5）: ")
        try:
            color_idx = int(sel_color)
            if 0 <= color_idx < len(COLOR_LIST):
                col_colors.append(COLOR_LIST[color_idx])
                break
            else:
                print("颜色序号超出范围，请重新输入。")
        except:
            print("输入格式错误，请重新输入。")

```

```

sns.set_theme(style="darkgrid", palette="pastel")
# palette = sns.color_palette("pastel", n_colors=len(cols)) # 删除 palette

fig, ax1 = plt.subplots(figsize=(11, 7))

# 横向直方图和密度曲线
for i, col in enumerate(cols):
    from scipy.stats import gaussian_kde
    col_data = data[col].dropna()
    kde = gaussian_kde(col_data)
    x = np.linspace(col_data.min(), col_data.max(), 200)
    density = kde(x)
    density = density / density.max() * 0.4 # 控制高度
    y_center = i

    # 绘制横向直方图
    hist, bin_edges = np.histogram(col_data, bins=20)
    hist = hist / hist.max() * 0.4 # 归一化高度
    for h, x0, x1 in zip(hist, bin_edges[:-1], bin_edges[1:]):
        ax1.fill_between([x0, x1], y_center - h/2, y_center + h/2,
                        color=col_colors[i], alpha=0.25)

    # 绘制横向密度曲线
    y_curve = y_center + density
    ax1.plot(x, y_curve, color=col_colors[i], alpha=0.7, linewidth=2)
    ax1.fill_between(x, y_center, y_curve, color=col_colors[i], alpha=0.2)

ax1.set_yticks(range(len(cols)))
ax1.set_yticklabels(cols, fontsize=12)
ax1.tick_params(axis='x', labelsize=12)
ax1.grid(True, linestyle='--', alpha=0.5)
force_chinese_font(ax1)
plt.tight_layout()

app = QApplication(sys.argv)
win = PlotWindow(fig)
win.show()
sys.exit(app.exec_())

if __name__ == '__main__':

```

```
main()
```

源程序 2: 绘制 Spearman 相关系数热力图的 Python 代码

```
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
import numpy as np

# 加中文字体支持
plt.rcParams['font.sans-serif'] = ['SimHei'] # 使用黑体
plt.rcParams['axes.unicode_minus'] = False # 正确显示负号

def main():
    file_path = input("请输入Excel文件路径: ").strip()
    try:
        df = pd.read_excel(file_path)
    except Exception as e:
        print(f"文件读取失败: {e}")
        return

    print("\n可选列名如下: ")
    for idx, col in enumerate(df.columns):
        print(f"{idx}: {col}")

    # 选择被研究变量
    while True:
        sel = input("\n请输入被研究变量的列序号 (可 个, 用空格分隔): ")
        try:
            indices = [int(i) for i in sel.split()]
            if all(0 <= i < len(df.columns) for i in indices):
                break
            else:
                print("序号超出范围, 请重新输入。")
        except:
            print("输入格式错误, 请重新输入。")

    research_cols = [df.columns[i] for i in indices]

    # 选择目标变量
```

```

while True:
    target_idx = input("\n请输入目标变量的列序号（只能一个）： ")
    try:
        target_idx = int(target_idx)
        if 0 <= target_idx < len(df.columns):
            break
        else:
            print("序号超出范围，请重新输入。")
    except:
        print("输入格式错误，请重新输入。")

target_col = df.columns[target_idx]

# 计算Spearman相关系数
spearman_values = []
for col in research_cols:
    coef = df[[col, target_col]].corr(method='spearman').iloc[0,1]
    spearman_values.append(coef)

# 构造相关系数DataFrame
corr_df = pd.DataFrame({target_col: spearman_values}, index=research_cols)

# 绘制热力图
plt.figure(figsize=(6, len(research_cols)*0.6+2))
sns.heatmap(corr_df, annot=True, cmap='coolwarm', vmin=-1, vmax=1,
            linewidths=0.5, cbar=True)
# plt.title(f"{target_col}与各变量的Spearman相关系数热力图")
plt.tight_layout()
plt.show()

if __name__ == "__main__":
    main()

```

源程序 3: Q3Y 染色体浓度

```

import pandas as pd
import numpy as np

# 读取数据
df = pd.read_excel('Q3数据.xlsx')

```

```

# 首先按照BMI进行分组 (BMI <= 33为0类, 其他为1类)
df['Cluster'] = np.where(df['孕妇BMI'] <= 33, 0, 1)

# 统计各组Y染色体浓度达到0.04的比例
result = df.groupby('Cluster').agg({
    'Y染色体浓度': [
        ('总样本数', 'count'),
        ('达标样本数', lambda x: (x >= 0.04).sum()),
        ('达标比例', lambda x: (x >= 0.04).mean() * 100), # 转换为百分比
        ('平均值', 'mean'),
        ('最小值', 'min'),
        ('最大值', 'max')
    ]
}).round(2)

# 重命名列以便更好的显示
result.columns = ['总样本数', '达标样本数', '达标比例(%)', '平均浓度',
    '最小浓度', '最大浓度']
result = result.reset_index()

print("=" * 60)
print("各组Y染色体浓度达标情况统计 (达标标准: 0.04)")
print("=" * 60)
print(result.to_string(index=False))

# 添加总计行
total_count = len(df)
total_qualified = (df['Y染色体浓度'] >= 0.04).sum()
total_ratio = total_qualified / total_count * 100

print("\n" + "=" * 60)
print("总体统计:")
print("=" * 60)
print(f"总样本数: {total_count}")
print(f"总体达标数: {total_qualified}")
print(f"总体达标比例: {total_ratio:.2f}%")

# 可视化结果
import matplotlib.pyplot as plt

```

```

import seaborn as sns

plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

fig, (ax1, ax2) = plt.subplots(1, 2, figsize=(15, 6))

# 1. 达标比例柱状图
ax1.bar(result['Cluster'].astype(str), result['达标比例(%)'],
        color=['skyblue', 'lightcoral'], alpha=0.7)
ax1.set_xlabel('聚类组别')
ax1.set_ylabel('达标比例 (%)')
ax1.set_title('各组Y染色体浓度达标比例\n( 0.04)')
ax1.grid(True, alpha=0.3)

# 在柱状图上添加数值标签
for i, v in enumerate(result['达标比例(%)']):
    ax1.text(i, v + 1, f'{v:.1f}%', ha='center', va='bottom',
            fontweight='bold')

# 2. Y染色体浓度分布箱线图
cluster_data = []
for cluster in result['Cluster']:
    cluster_data.append(df[df['Cluster'] == cluster]['Y染色体浓度'])

ax2.boxplot(cluster_data, labels=result['Cluster'].astype(str))
ax2.axhline(y=0.04, color='red', linestyle='--', alpha=0.7, label='达标阈值\n(0.04)')
ax2.set_xlabel('聚类组别')
ax2.set_ylabel('Y染色体浓度')
ax2.set_title('各组Y染色体浓度分布')
ax2.grid(True, alpha=0.3)
ax2.legend()

plt.tight_layout()
plt.show()

# 详细的统计检验（可选）
from scipy import stats

```

```

# 提取两组的Y染色体浓度数据
group0 = df[df['Cluster'] == 0]['Y染色体浓度']
group1 = df[df['Cluster'] == 1]['Y染色体浓度']

# 进行t检验，比较两组均值是否有显著差异
t_stat, p_value = stats.ttest_ind(group0, group1, equal_var=False)

print("\n" + "=" * 60)
print("统计检验结果:")
print("=" * 60)
print(f"组0平均浓度: {group0.mean():.4f}")
print(f"组1平均浓度: {group1.mean():.4f}")
print(f"t统计量: {t_stat:.4f}")
print(f"p值: {p_value:.4f}")

if p_value < 0.05:
    print("结论: 两组Y染色体浓度存在显著差异 (p < 0.05)")
else:
    print("结论: 两组Y染色体浓度无显著差异 (p > 0.05)")

# 保存详细结果到Excel
detailed_result = df.groupby('Cluster').apply(lambda x: pd.Series({
    '总样本数': len(x),
    '达标样本数': (x['Y染色体浓度'] >= 0.04).sum(),
    '达标比例(%)': (x['Y染色体浓度'] >= 0.04).mean() * 100,
    '平均浓度': x['Y染色体浓度'].mean(),
    '浓度标准差': x['Y染色体浓度'].std(),
    '浓度中位数': x['Y染色体浓度'].median(),
    '浓度25分位数': x['Y染色体浓度'].quantile(0.25),
    '浓度75分位数': x['Y染色体浓度'].quantile(0.75)
})).reset_index()

detailed_result.to_excel('Y染色体浓度达标统计.xlsx', index=False)
print(f"\n详细统计结果已保存到 'Y染色体浓度达标统计.xlsx'")

```

源程序 4: Q3 聚类

```

import pandas as pd
import numpy as np
from sklearn.preprocessing import StandardScaler

```

```

from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score, davies_bouldin_score,
    calinski_harabasz_score
import matplotlib.pyplot as plt
import seaborn as sns

# 设置中文字体
plt.rcParams['font.sans-serif'] = ['SimHei']
plt.rcParams['axes.unicode_minus'] = False

# 读取数据
df = pd.read_excel('Q3数据.xlsx')

# 选择指定的6个特征
features = ['体重', '孕妇BMI', '原始读段数', '唯一比对的读段数', 'X染色体浓度',
    '被过滤掉读段数的比例']
X = df[features].copy()

# 数据预处理：处理缺失值
X = X.dropna()

# 数据标准化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# 确定K值范围
k_range = range(2, 8)
results = [] # 存储每个K值的评估结果

# 计算每个K值的聚类评估指标
for k in k_range:
    kmeans = KMeans(n_clusters=k, init='k-means++', random_state=42, n_init=10)
    cluster_labels = kmeans.fit_predict(X_scaled)

    # 计算三个评估指标
    si = silhouette_score(X_scaled, cluster_labels) # 轮廓系数（越大越好）
    dbi = davies_bouldin_score(X_scaled, cluster_labels) #
        戴维森堡丁指数（越小越好）
    chi = calinski_harabasz_score(X_scaled, cluster_labels) #
        卡林斯基-哈拉巴斯指数（越大越好）

```

```

results.append({
    'k': k,
    'SI': si,
    'DBI': dbi,
    'CHI': chi,
    'inertia': kmeans.inertia_,
    'model': kmeans
})

# 提取指标值
si_scores = [result['SI'] for result in results]
dbi_scores = [result['DBI'] for result in results]
chi_scores = [result['CHI'] for result in results]

# 归一化处理（使所有指标都在0-1范围内，且都是越大越好）
def normalize_scores(scores, reverse=False):
    """归一化得分，reverse=True表示原始值越小越好"""
    scores = np.array(scores)
    if reverse:
        # 对于越小越好的指标（如DBI），取倒数再归一化
        scores = 1 / scores
    min_val = np.min(scores)
    max_val = np.max(scores)
    if max_val == min_val:
        return np.ones_like(scores)
    return (scores - min_val) / (max_val - min_val)

si_normalized = normalize_scores(si_scores) # SI越大越好
dbi_normalized = normalize_scores(dbi_scores, reverse=True) #
    DBI越小越好，所以取反
chi_normalized = normalize_scores(chi_scores) # CHI越大越好

# 计算综合得分（可以根据需要调整权重）
composite_scores = []
for i in range(len(k_range)):
    composite_score = 0.4 * si_normalized[i] + 0.3 * dbi_normalized[i] + 0.3 *
        chi_normalized[i]

```

```

    composite_scores.append(composite_score)

# 找到最佳K值
best_idx = np.argmax(composite_scores)
optimal_k = k_range[best_idx]
best_result = results[best_idx]

print("=" * 60)
print("聚类评估指标结果:")
print("=" * 60)
for i, result in enumerate(results):
    print(f"K={result['k']}: SI={result['SI']:.4f}, DBI={result['DBI']:.4f}, "
          f"CHI={result['CHI']:.0f}, "
          f"f"综合得分={composite_scores[i]:.4f}")

print("=" * 60)
print(f"\n最佳K值: {optimal_k}")
print(f"综合得分: {composite_scores[best_idx]:.4f}")
print(f"轮廓系数(SI): {best_result['SI']:.4f}")
print(f"戴维森堡丁指数(DBI): {best_result['DBI']:.4f}")
print(f"卡林斯基-哈拉巴斯指数(CHI): {best_result['CHI']:.0f}")
print("=" * 60)

# 可视化评估指标
fig, ((ax1, ax2), (ax3, ax4)) = plt.subplots(2, 2, figsize=(15, 12))

# 轮廓系数图
ax1.plot(k_range, si_scores, 'bo-', label='SI Score')
ax1.set_xlabel('聚类数 (k)')
ax1.set_ylabel('轮廓系数 (SI)')
ax1.set_title('轮廓系数 - 越大越好')
ax1.grid(True)
ax1.legend()

# 戴维森堡丁指数图
ax2.plot(k_range, dbi_scores, 'ro-', label='DBI Score')
ax2.set_xlabel('聚类数 (k)')
ax2.set_ylabel('戴维森堡丁指数 (DBI)')
ax2.set_title('戴维森堡丁指数 - 越小越好')

```

```

ax2.grid(True)
ax2.legend()

# 卡林斯基-哈拉巴斯指数图
ax3.plot(k_range, chi_scores, 'go-', label='CHI Score')
ax3.set_xlabel('聚类数 (k)')
ax3.set_ylabel('卡林斯基-哈拉巴斯指数 (CHI)')
ax3.set_title('卡林斯基-哈拉巴斯指数 - 越大越好')
ax3.grid(True)
ax3.legend()

# 综合得分图
ax4.plot(k_range, composite_scores, 'mo-', label='综合得分')
ax4.scatter(optimal_k, composite_scores[best_idx], color='red', s=100,
            zorder=5, label=f'最佳K值 ({optimal_k})')
ax4.set_xlabel('聚类数 (k)')
ax4.set_ylabel('综合得分')
ax4.set_title('综合评估得分 - 越大越好')
ax4.grid(True)
ax4.legend()

plt.tight_layout()
plt.show()

# 使用最佳K值进行最终聚类
final_kmeans = results[best_idx]['model']
df_filtered = df.loc[X.index].copy() # 只保留没有缺失值的行
df_filtered['cluster'] = final_kmeans.labels_

# 统计每个类别的BMI区间
cluster_bmi_stats = df_filtered.groupby('cluster')['孕妇BMI'].agg([
    ('样本数', 'count'),
    ('BMI最小值', 'min'),
    ('BMI最大值', 'max'),
    ('BMI平均值', 'mean'),
    ('BMI标准差', 'std'),
    ('BMI范围', lambda x: f'{x.min():.1f}-{x.max():.1f}')
]).reset_index()

print("\n各聚类类别的BMI统计信息:")

```

```

print(cluster_bmi_stats.to_string(index=False))

# 可视化聚类结果
plt.figure(figsize=(15, 10))

# BMI分布箱线图
plt.subplot(2, 2, 1)
sns.boxplot(x='cluster', y='孕妇BMI', data=df_filtered)
plt.title('各聚类类别的BMI分布')
plt.xlabel('聚类类别')
plt.ylabel('孕妇BMI')

# 聚类中心热力图
plt.subplot(2, 2, 2)
cluster_centers = final_kmeans.cluster_centers_
cluster_centers_original = scaler.inverse_transform(cluster_centers)
cluster_center_df = pd.DataFrame(cluster_centers_original, columns=features)
sns.heatmap(cluster_center_df, annot=True, cmap='YlOrRd', fmt='.2f')
plt.title('各聚类中心特征值')

# 特征重要性分析
plt.subplot(2, 2, 3)
feature_importance = np.std(cluster_centers, axis=0)
feature_importance_df = pd.DataFrame({
    '特征': features,
    '重要性': feature_importance
}).sort_values('重要性', ascending=False)

sns.barplot(x='重要性', y='特征', data=feature_importance_df)
plt.title('特征在聚类中的重要性')

# 样本分布饼图
plt.subplot(2, 2, 4)
cluster_counts = df_filtered['cluster'].value_counts()
plt.pie(cluster_counts.values, labels=[f'聚类 {i}' for i in
    cluster_counts.index],
    autopct='%1.1f%%', startangle=90)
plt.title('各聚类样本分布')

plt.tight_layout()

```

```

plt.show()

# 输出详细的聚类描述
print("\n" + "=" * 60)
print("详细聚类分析结果")
print("=" * 60)
for cluster_id in range(optimal_k):
    cluster_data = df_filtered[df_filtered['cluster'] == cluster_id]
    print(f"\n聚类 {cluster_id} (共{len(cluster_data)}个样本):")
    print(f"BMI范围: {cluster_data['孕妇BMI'].min():.1f} - {cluster_data['孕妇BMI'].max():.1f}")
    print(f"平均BMI: {cluster_data['孕妇BMI'].mean():.2f} ± {cluster_data['孕妇BMI'].std():.2f}")

# 输出其他特征的平均值
print("其他特征平均值:")
for feature in features:
    if feature != '孕妇BMI':
        print(f" {feature}: {cluster_data[feature].mean():.2f}")

# 保存结果到Excel
result_df = df_filtered[['孕妇代码', '孕妇BMI', 'cluster'] + features]
result_df.to_excel('聚类分析结果.xlsx', index=False)

print(f"\n分析完成！最佳聚类数为 {optimal_k}，结果已保存到 '聚类分析结果.xlsx'")

```

源程序 5: 筛选数据

```

import pandas as pd

# 读取数据
df = pd.read_excel('Q3数据_分类结果.xlsx')

df_filtered = df[df['染色体的非整倍体'] == df['胎儿是否健康']].copy()

# 查看筛选结果
print(f"原始数据形状: {df.shape}")
print(f"筛选后数据形状: {df_filtered.shape}")
print(f"Cluster值分布:")

```

```
print(df_filtered['Cluster'].value_counts())

# 将筛选后的数据保存到新文件（或覆盖原文件）
df_filtered.to_excel('Q3数据_第二类误差.xlsx', index=False)
# 或者覆盖原文件（谨慎使用）：
# df_filtered.to_excel('Q3数据_分类结果.xlsx', index=False)

print("筛选完成！数据已保存")
```

C 数据集




图 20: 问题一中数据分布图